PREDICTING HEATING AND COOLING LOADS OF BUILDINGS USING MACHINE LEARNING MODELS

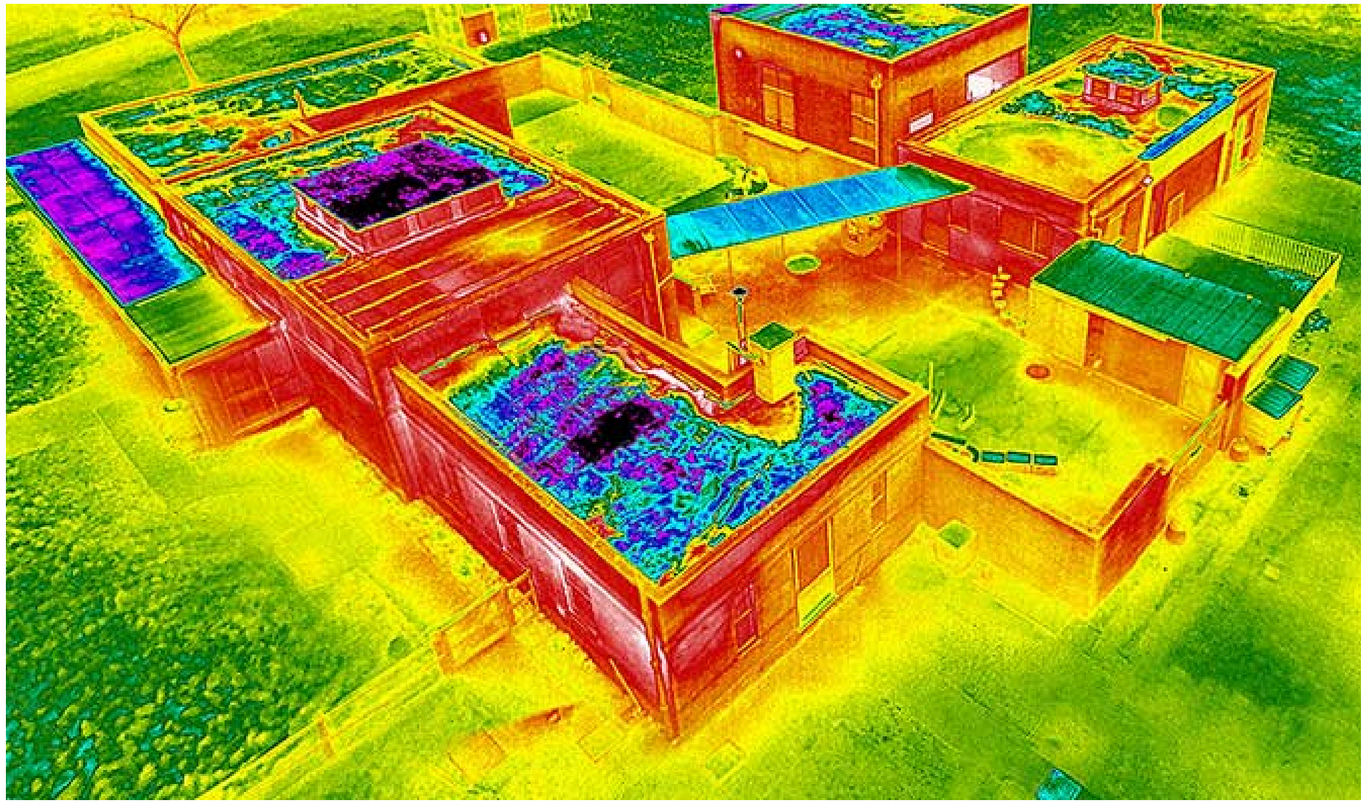

Hồ Nhật Tân

Phan Tiến Đạt

OUR CONTENTS

01. Introduction

02. Main Contribution

03. Experimental Pipeline

04. Results & Discussion

05. Conclusion & Future Work

INTRODUCTION

Mục tiêu chính:

- Tối ưu hóa hiệu quả năng lượng (Energy Efficiency) trong thiết kế kiến trúc bền vững.

Vấn đề đặt ra:

- Các phương pháp mô phỏng truyền thống (simulations) tốn kém tài nguyên và thời gian.
- Cần công cụ dự báo nhanh, chính xác ngay từ giai đoạn thiết kế sớm.

Giải pháp:

- Sử dụng các mô hình Machine Learning Regression để ước tính tải nhiệt dựa trên các thông số thiết kế.

Thử thách kỹ thuật:

- Các thuộc tính đầu vào (features) có độ tương quan (correlation) cao.
- Mối quan hệ giữa thiết kế và tải nhiệt có thể là phi tuyến (nonlinear).

MAIN CONTRIBUTION

A. PROBLEM FORMULATION

- **Loại bài toán:** Supervised Regression (Hồi quy có giám sát).
- **Dữ liệu đầu vào:** Ma trận đặc trưng $X \in \mathbb{R}^{n \times 8}$ (8 thông số thiết kế).
- **Dữ liệu đầu ra:** Ma trận mục tiêu $Y \in \mathbb{R}^{n \times 2}$ (Heating & Cooling Loads).
- **Mục tiêu:** Tối tiểu hóa hàm mất mát (Loss function):

$$\min_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^{n} \mathcal{L}(\mathbf{y}_i, f(\mathbf{x}_i))$$

- **Hai chiến lược tiếp cận:**
  1. **Independent Modeling:** Huấn luyện các mô hình riêng biệt cho từng đầu ra.
  2. **Joint Modeling (Multi-output):** Dự đoán đồng thời cả hai đầu ra bằng một cấu trúc tham số chung.

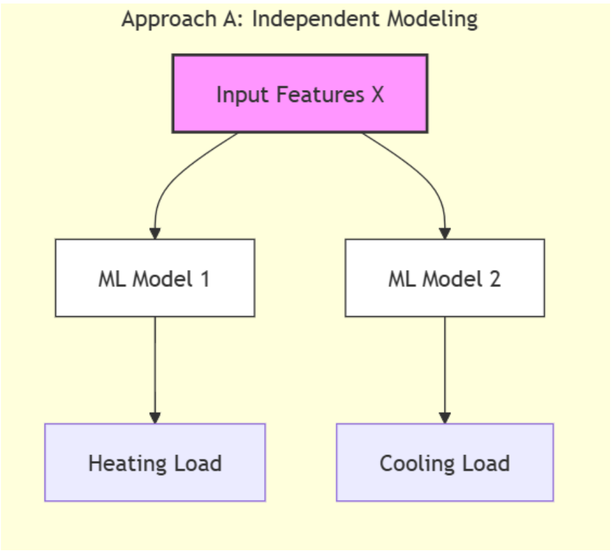

Fig 2. Single-output Regression Workflow

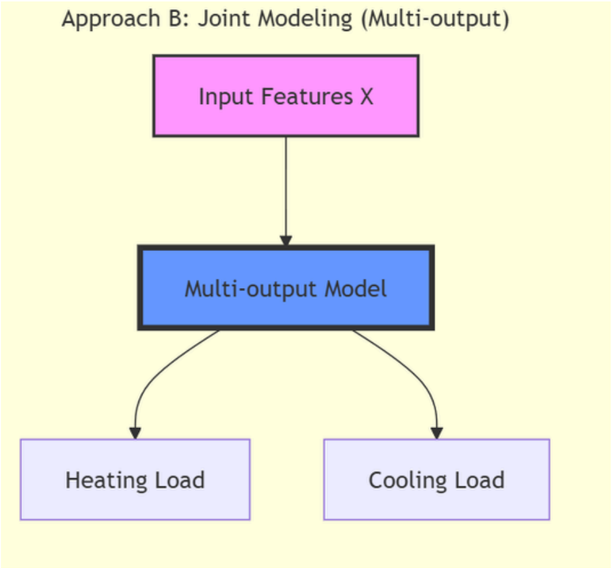

Fig 3. Multi-output Regression Workflow

MAIN CONTRIBUTION

B. LINEAR REGRESSION & REGULARIZATION

- **Ordinary Least Squares (OLS):** Mô hình cơ sở, tối thiểu hóa sai số bình phương (RSS).
- **Ridge Regression (L2 Regularization):** Thêm hình phạt bình phương trọng số để giảm hiện tượng đa cộng tuyến.
- **Lasso Regression (L1 Regularization):** Thêm hình phạt giá trị tuyệt đối, giúp triệt tiêu các đặc trưng không quan trọng.

Công thức OLS: $\min_{\mathbf{w},b} \sum_{i=1}^{N} \left(y_i - (\mathbf{w}^\top \mathbf{x}_i + b)\right)^2$

Hình phạt Ridge: $R_{Ridge}(\mathbf{w}) = \|\mathbf{w}\|_2^2$

Hình phạt Lasso: $R_{Lasso}(\mathbf{w}) = \|\mathbf{w}\|_1$

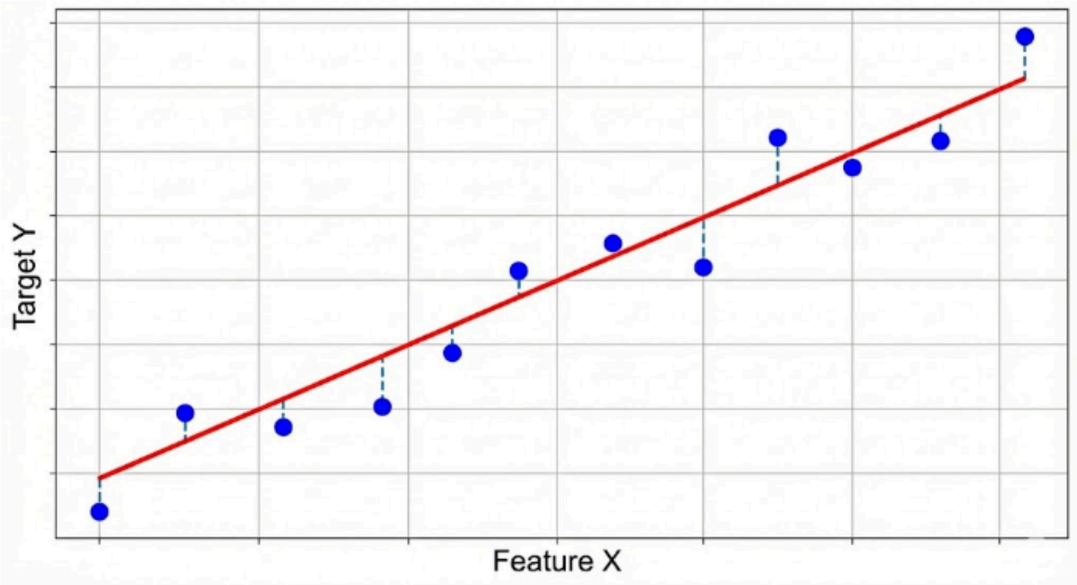

Fig 4. Illustration of single-output linear regression, showing the linear relationship between an input feature and a single target variable.

MAIN CONTRIBUTION

C. MULTI-OUTPUT LINEAR REGRESSION

- **Khái niệm:** Dự đoán đồng thời Heating Load (**HL**) và Cooling Load (**CL**) thay vì tách rời.
- **Lý do sử dụng:** Tận dụng mối liên hệ thống kê (statistical dependence) giữa **HL** và **CL** (vì chúng cùng thuộc một hệ thống vật lý của tòa nhà).
- **Cơ chế:** Sử dụng một ma trận trọng số chung **W** để ánh xạ từ đầu vào đến cả hai đầu ra.
- **Regularization:** Sử dụng chuẩn Frobenius để kiểm soát độ phức tạp của toàn bộ ma trận trọng số.

Mô hình: $\mathbf{y} = \mathbf{W}^\top \mathbf{x} + \mathbf{b}$

Hàm tối ưu (Loss function): $\min_{\mathbf{W}} \|\mathbf{Y} - \mathbf{X}\mathbf{W}\|_F^2 + \lambda \Omega(\mathbf{W})$

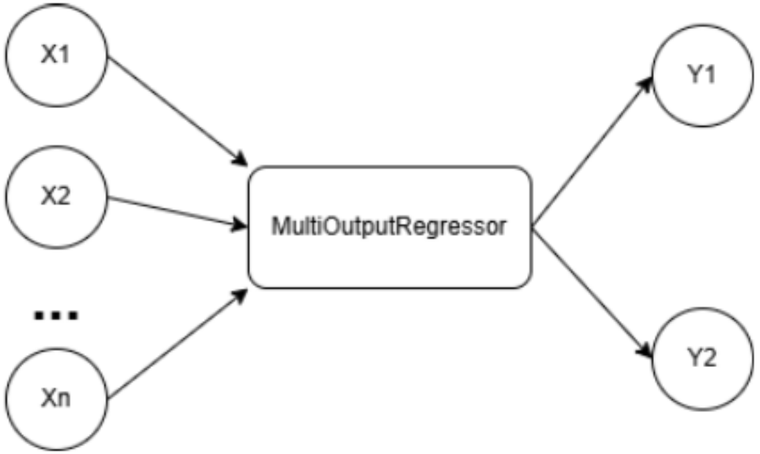

Fig 5. Illustration of the multi-output regression model used in this study, where the input features X1, X2, . . . , Xn are used to predict two target variables Y1 and Y2.

MAIN CONTRIBUTION

D. SUPPORT VECTOR REGRESSION (SVR)

- **Nguyên lý:** SVR tìm một hàm f(x) sao cho dữ liệu nằm trong một "ống" sai số ε
- **Cơ chế đặc biệt:** Các sai số nằm trong ống không bị phạt.
  - Các điểm ngoài ống được xử lý bằng biến bù trừ
- **Mô hình tuyến tính:** **f(x)=⟨w,x⟩+b**
- **Ưu điểm:** Tăng độ ổn định (robustness) và hạn chế ảnh hưởng của nhiễu trong dữ liệu năng lượng tòa nhà.

Hàm tối ưu:

$$\min_{\mathbf{w}} \frac{1}{2}\|\mathbf{w}\|_2^2 + C\sum_{i=1}^{n} \max(0, |y_i - \mathbf{w}^T\mathbf{x}_i| - \varepsilon)$$

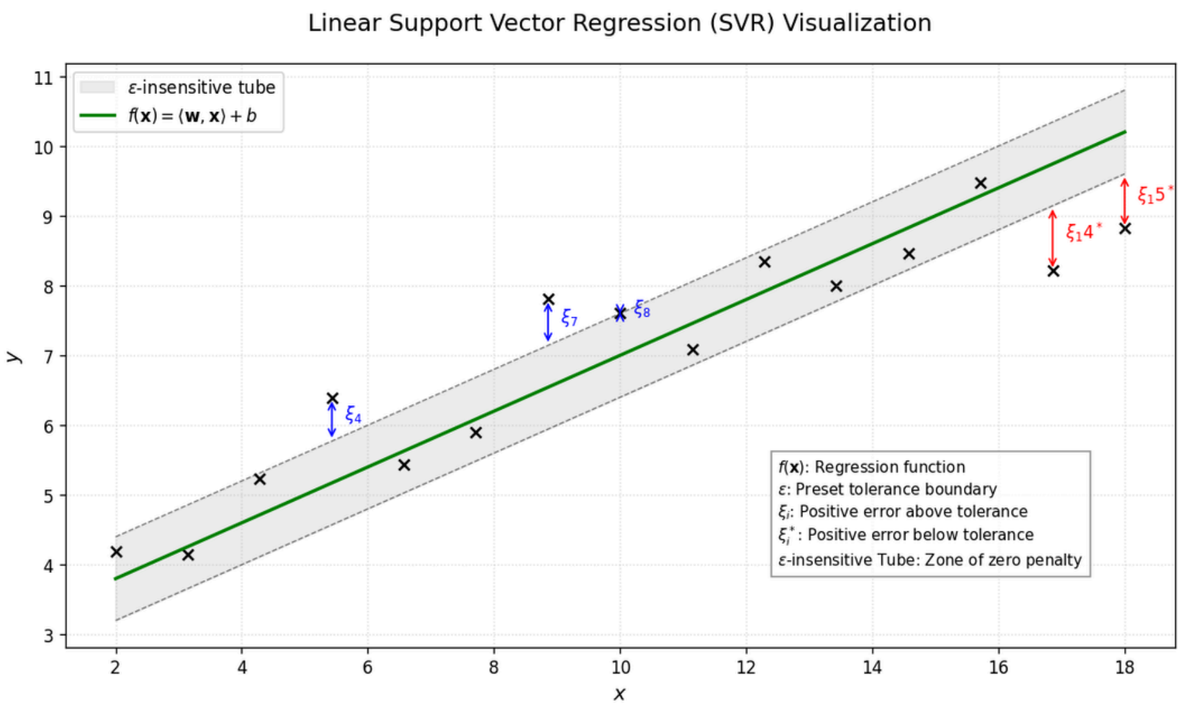

Fig 6. Illustration of linear Support Vector Regression showing the regression function, the ε- insensitive tube, and slack variables.

MAIN CONTRIBUTION

E. KERNEL-BASED SVR

- **Hạn chế:** Các mô hình tuyến tính (Linear) không bắt kịp mối quan hệ phức tạp, phi tuyến giữa kiến trúc và nhiệt độ.
- **Giải pháp:** Kernel Trick.
  - Ánh xạ dữ liệu từ không gian đặc trưng ban đầu sang không gian cao chiều hơn.
  - Xây dựng siêu phẳng (hyperplane) tối ưu trong không gian mới.
- **Radial Basis Function (RBF) Kernel:**
  - Được lựa chọn nhờ khả năng mô hình hóa linh hoạt các mẫu dữ liệu phức tạp.
  - Tham số gamma điều khiển tầm ảnh hưởng của từng điểm dữ liệu.

Hàm Kernel RBF:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2\right)$$

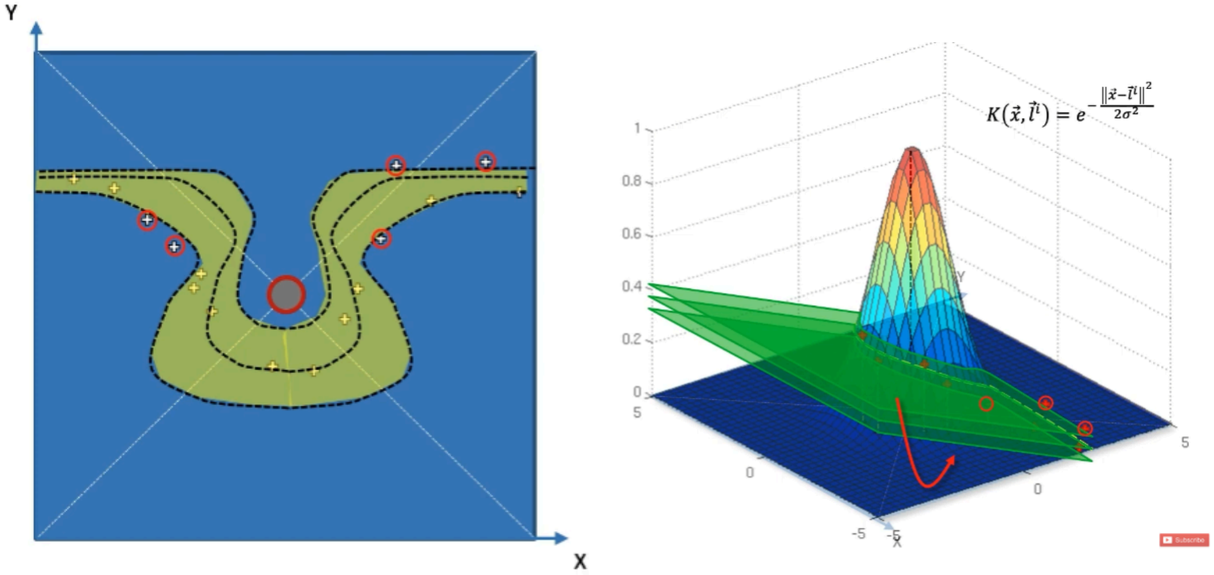

Fig 7. Visualization of non-linear SVR using the kernel trick: (Left) Non-linear regression tube in the original 2D feature space (Right) Mapping of input data into a high-dimensional feature space using an RBF kernel where a linear hyperplane is constructed.

MAIN CONTRIBUTION

F. UNIFIED MACHINE LEARNING PIPELINE

- **Data Partitioning:** Chia tập dữ liệu theo tỷ lệ 80% Training - 20% Testing.
- **Feature Standardization:** Chuẩn hóa dữ liệu về cùng một thang đo (Z-score scaling) để tránh sự chênh lệch lớn giữa các thuộc tính (như Surface Area vs Glazing Area).
- **Hyperparameter Tuning:** Sử dụng 5-fold Cross-Validation trên tập Training để tìm bộ tham số tối ưu (như C, ε, γ).
- **Evaluation:** Đánh giá cuối cùng trên tập Test độc lập để đảm bảo tính khách quan (không bị overfitting).

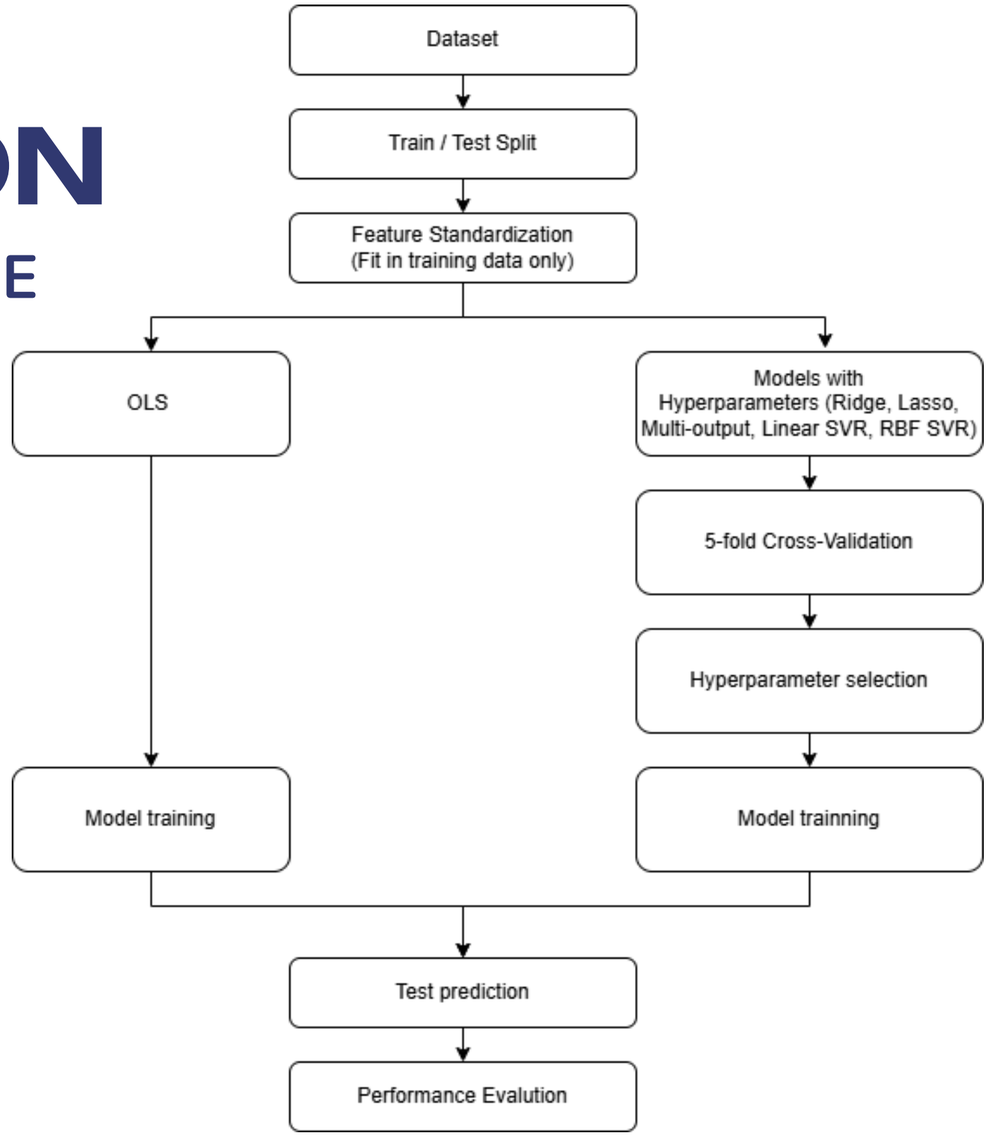

Fig 8. Unified machine learning pipeline used for training and evaluating all predictive models. Hyperparameter tuning via 5 fold cross-validation is applied only to models with tunable parameters, while OLS is trained directly on the training data.

DATASET ANALYSIS

- **Nguồn:** Energy Efficiency Dataset (768 mẫu).
- **Đặc trưng đầu vào (8 Features - X1 đến X8):**
  - Diện tích bề mặt, Diện tích mái, Diện tích tường, Chiều cao tổng thể, tỷ lệ kính (Glazing Area) và sự phân bổ của chúng.
- **Biến mục tiêu** (2 Targets):
  - Heating Load (HL - Tải sưởi).
  - Cooling Load (CL - Tải làm mát).
- **Đặc điểm dữ liệu:** Toàn bộ là biến số, không có giá trị thiếu, không có giá trị ngoại lai.

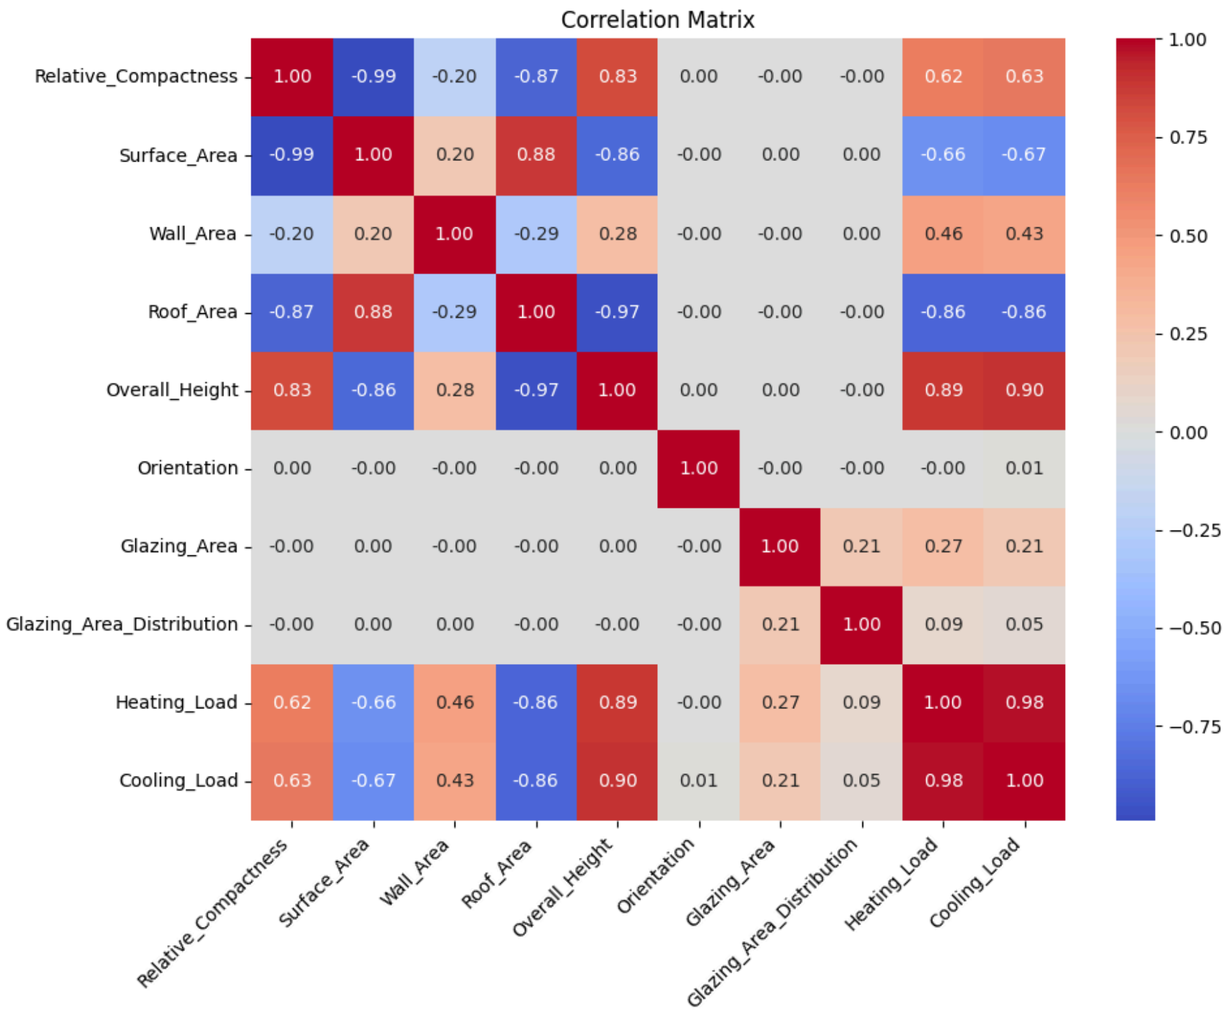

Fig1. Correlation matrix of input features and target variables.

EXPERIMENTAL RESULTS

Table 1: Prediction performance of different models.

Model	**HL_MAE**	**HL_RMSE**	**CL_MAE**	**CL_RMSE**
OLS	2.1821	3.0254	2.1953	3.1454
Ridge	2.1829	3.0264	2.1949	3.1457
Lasso	2.1832	3.0262	2.1945	3.1455
Multi-output Ridge	2.1829	3.0264	2.1949	3.1457
Multi-output Lasso	2.1828	3.0259	2.1947	3.1455
Linear SVR	2.1250	3.0679	2.1776	3.2797
RBF SVR	**0.3416**	**0.4663**	**0.9128**	**1.5500**

DISCUSSION

- **Linear Modeling & Regularization:**
  - Các mô hình tuyến tính (OLS, Ridge, Lasso) cho kết quả tương đương nhau.
  - Regularization không giúp cải thiện đáng kể sai số. Mô hình tuyến tính cơ bản đã nắm bắt hết các mối quan hệ tuyến tính có thể.
- **Output Coupling:**
  - Multi-output không làm tăng độ chính xác so với Single-output trong trường hợp này.
  - Tuy nhiên, nó cung cấp một khung làm việc thống nhất và gọn nhẹ hơn cho các bài toán đa mục tiêu.
- **Non-linear Modeling:**
  - RBF SVR vượt trội hoàn toàn (giảm sai số khoảng 85% so với mô hình tuyến tính).
  - Kết luận: Mối quan hệ giữa các thông số thiết kế (diện tích mái, chiều cao, độ nén...) và tải nhiệt mang tính phi tuyến cực kỳ phức tạp.

CONCLUSION & FUTURE WORK

Kết luận

- **Hiệu quả mô hình:** RBF-based SVR là mô hình tối ưu nhất, đạt độ chính xác vượt trội so với các mô hình tuyến tính truyền thống.
- **Bản chất dữ liệu:** Mối quan hệ giữa các thông số thiết kế tòa nhà và tải nhiệt mang tính phi tuyến phức tạp, đòi hỏi các kỹ thuật kernel-based để bắt kịp quy luật.
- **Tính ứng dụng:** Mô hình đề xuất có thể hỗ trợ kiến trúc sư dự báo nhanh nhu cầu năng lượng ngay từ giai đoạn phác thảo, giúp tiết kiệm thời gian và chi phí mô phỏng.

Hướng phát triển

- **Mô hình nâng cao:** Thử nghiệm với các thuật toán Ensemble (Random Forest, XGBoost) hoặc Deep Learning (Neural Networks) để tăng cường độ chính xác.
- **Feature Engineering:** Nghiên cứu thêm các đặc trưng kiến trúc mới hoặc sự tương tác giữa các biến để tối ưu đầu vào.
- **Dữ liệu thực tế:** Mở rộng tập dữ liệu từ các tòa nhà thực tế thay vì chỉ dựa trên dữ liệu mô phỏng

THANK YOU

Thanks For Watching

Presented by Group 2